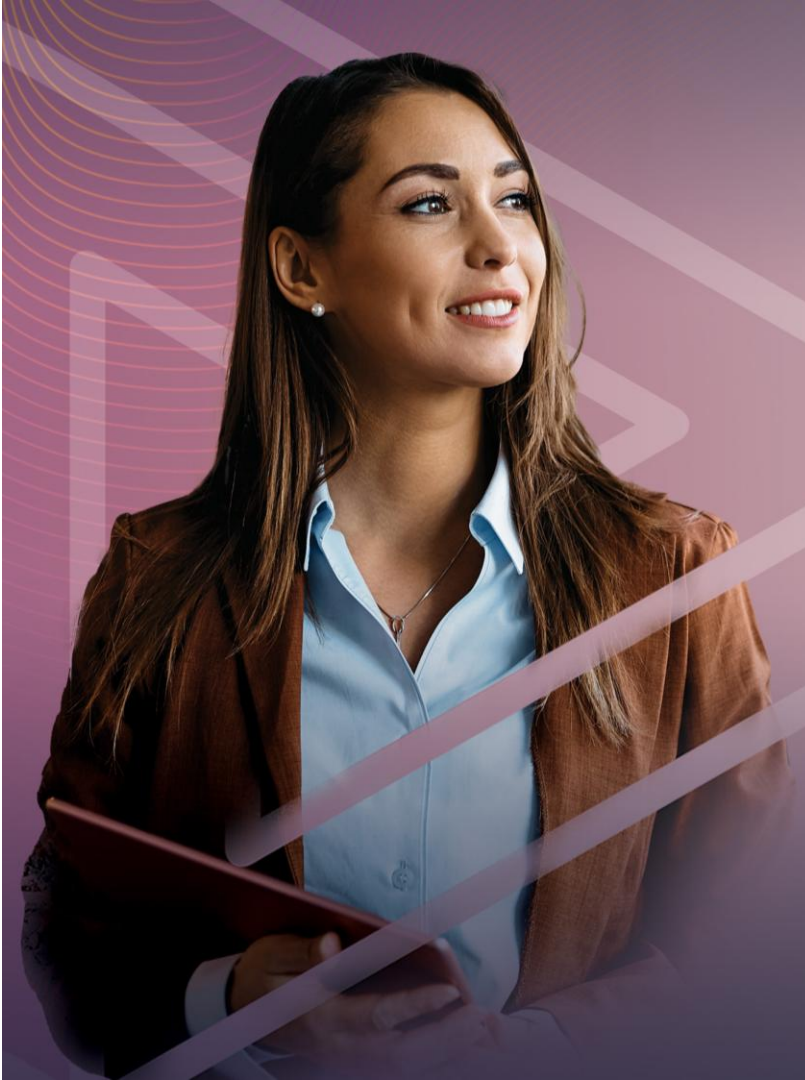

Universidad del Rosario

SEMINARIO TENDENCIAS DE LA INTELIGENCIA ARTIFICIAL (IA) EN SALUD

Machine Learning - ML No Supervisado

Fabián Sánchez
Escuela de Ciencias e Ingeniería
Universidad del Rosario

Alvaro David Orjuela Cañón
Escuela de Medicina y Ciencias de la Salud
Universidad del Rosario

ADVANCE
Educación Continua

Para una vida con ***PROPÓSITO***

Agenda

- Introducción
- Agrupamiento
- Algoritmos de Agrupamiento
  - Métodos Aglomerativos
  - Métodos Basados en Partición
  - Métodos Basados en Densidad
  - Métodos Basados en Redes Neuronales
- Algoritmo Ejemplos
- Ejemplos (SOM + *k-means*)

¿Qué es la Inteligencia Artificial?

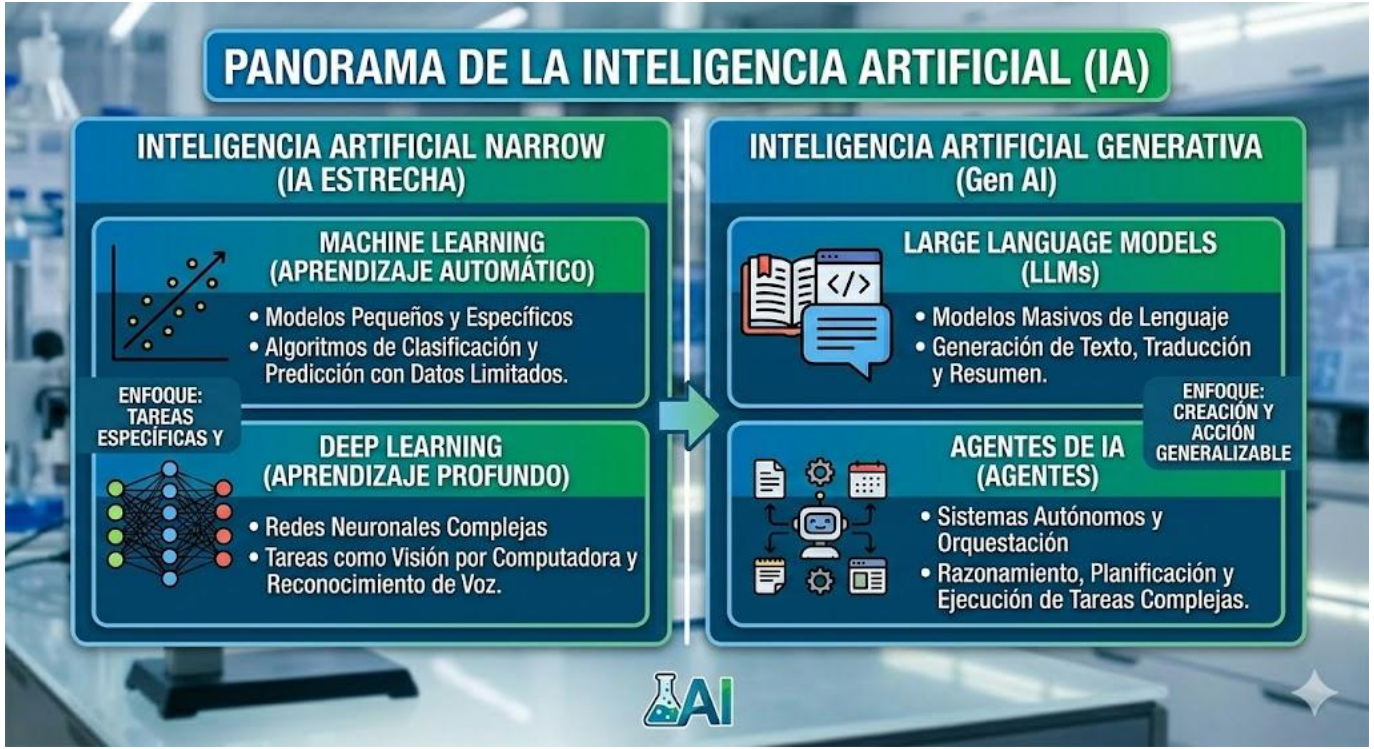

Introducción al Aprendizaje Automático (*Machine Learning)*

Aprendizaje NO Supervisado

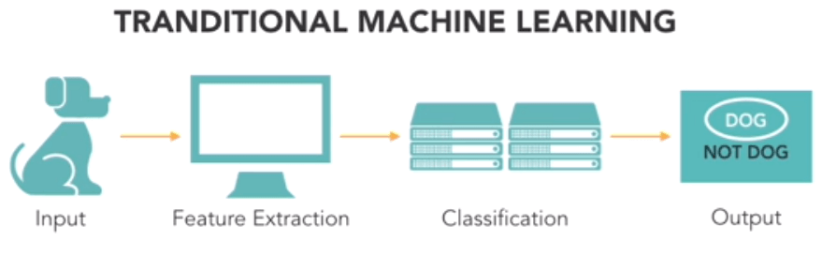

Generalidades

Objetivo: Obtener una función ***h(X)*** que solucione **el problema** basado en datos

Supervisado

Basado en minimización de error

- Clasificación
- Regresión/Estimación

No supervisado

Basado en similitud

- Agrupamiento
- Asociación

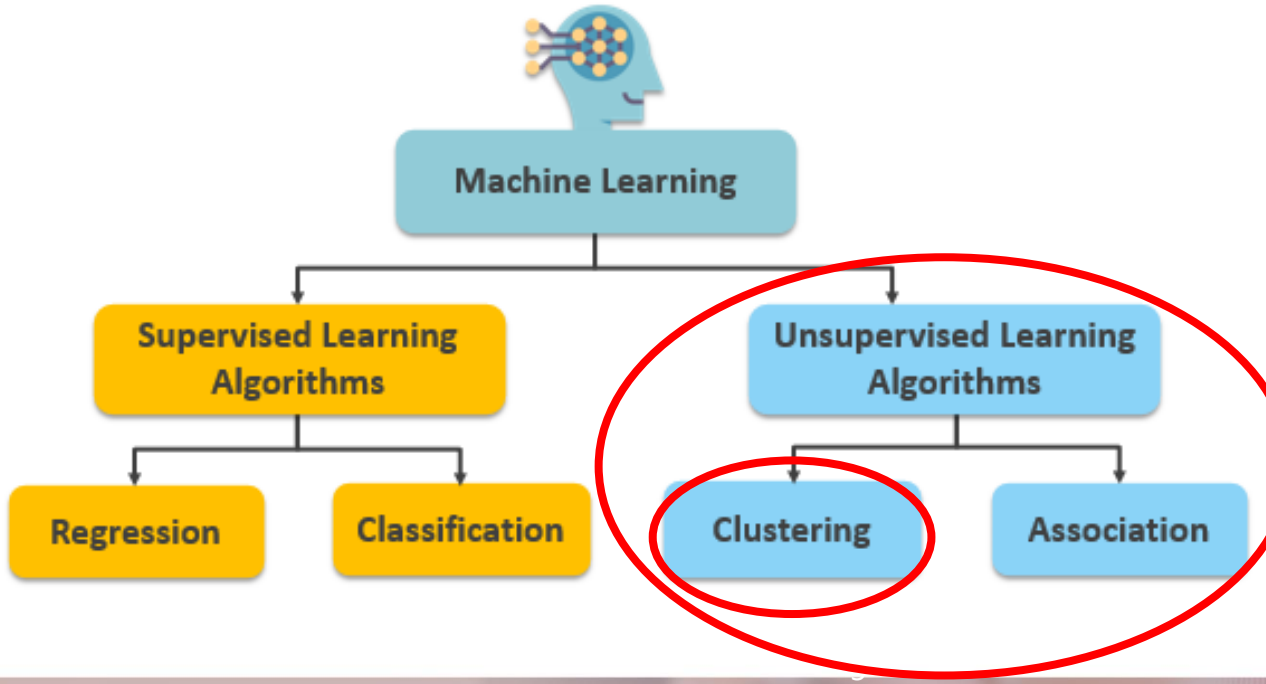

Introducción

Introducción (1/3)

Agrupamiento (*clustering*): identificar de forma automática grupos (o *clusters*) de elementos, basados en una medida de similitud

Proceso de Minería de Datos (*Data Mining)* :

- Definición del problema
- Adquisición de los datos
- Preproceso de los datos
- Modelado
- Evaluación
- Extracción de conocimiento.

Introducción (2/3)

Es decir …

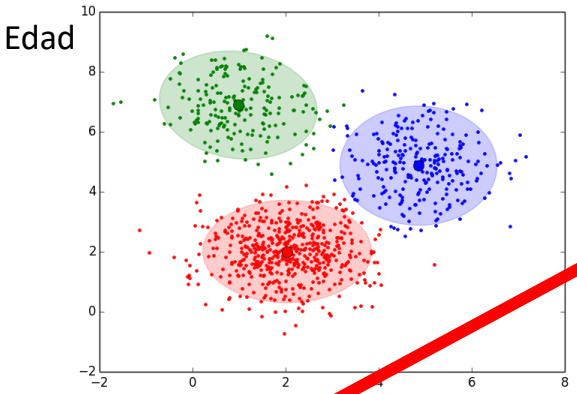

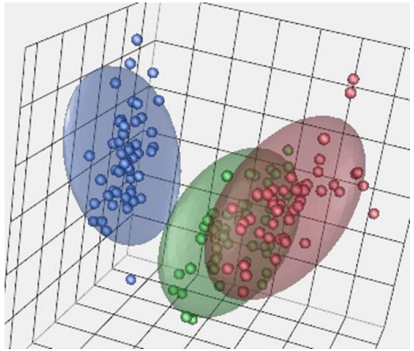

Edad	Ingreso	Estrato	Tipo de contrato	Industria
23	$1200000	3	Fijo	Petróleo
41	$3100000	3	Indefinido	Comunicaciones
…	…	…	…	…

Introducción (3/3)

Aspectos importantes

¿Qué características usar?

¿Qué medidas de similitud usar?

¿Qué método o algoritmo de conglomerado usar?

¿Cuantos grupos se deben formar?

¿Cómo asignar las filas (o columnas) a las agrupaciones?

¿Cómo validar las agrupaciones que se han formado?

Agrupamiento (*Clustering*) (1/3)

1. Inspección Visual
2. Algoritmo a usar
   - Jerárquico
     - Aglomerativos
     - Divisivos
   - Partición
     - Probabilistico
     - K-means
     - **Redes Neuronales**
3. Validación
   - Índice Davies-Bouldin
   - Índice Silueta

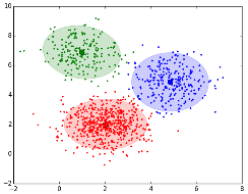

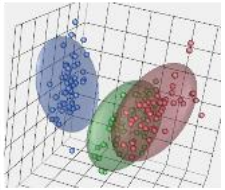

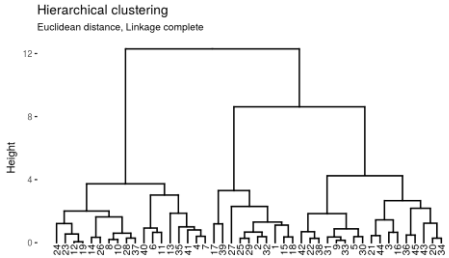

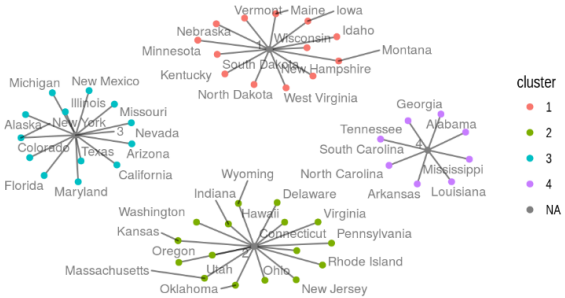

$$DB = \frac{1}{N}\sum_{i=1}^{N}\max_{i\neq j}\left(\frac{S_i + S_j}{d(c_i, c_j)}\right)$$

Agrupamiento (*Clustering*) (2/3)

- **Conceptos**:
  - Distancia Intra-cluster
  - Distancia entre-clusters

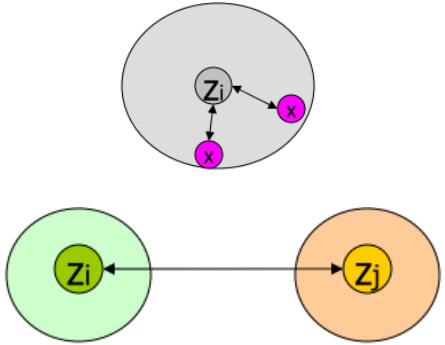

- **Medidas:**
  - Distancia Euclidiana

$$d_p(\mathrm{x},\mathrm{y}) = \left(\sum_{i=1}^{n} |x_i - y_i|^p\right)^{\frac{1}{p}} \quad \in \Re^l$$

  - Distancia de Mahalanobis

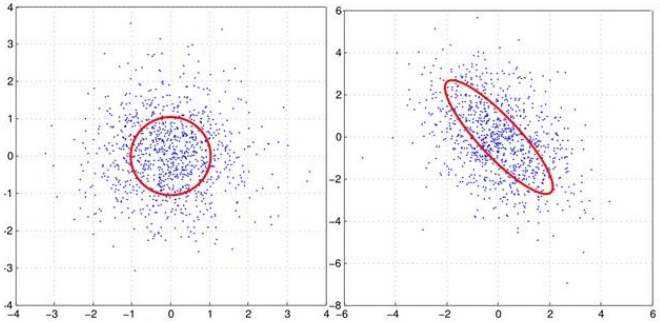

Agrupamiento (*Clustering*) (3/3)

- **Medidas de calidad de agrupamiento**:El índice Davies-Bouldin es un valor que independiente del número de agrupamientos es mide la calidad del mismo

$$I_{DB} = \frac{1}{C}\sum_{k=1}^{C}\max_{l\neq k}\left\{\frac{S_c(Q_k)+S_c(Q_l)}{d_{ce}(Q_k,Ql)}\right\}$$

Q es cada clúster, ***C*** es el número de clústeres, ***Sc*** es la medida de similitud intra-clúster

$$S_c = \frac{1}{N_k}\sum_{i=1}^{N_k}\|x_i - c_k\| \qquad d_{ce} = \|c_k - c_l\|$$

N_k es el número de elementos del clúster ***C_k*** y ***d_{ce}*** es la distancia entre clústeres

En cuanto menor sea el índice Davies-Bouldin un mejor agrupamiento de los datos es obtenido.

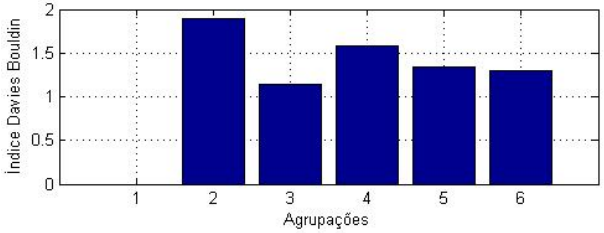

Algoritmos de Agrupamiento

Introducción (3/3)

Métodos Aglomerativos

- Algoritmo *Linkage*

Métodos Basados en Partición

- Algoritmo *KMeans*

Métodos Basados en Densidad

- *Density-Based Spatial Clustering of Applications with Noise* (DBSCAN)

Métodos Basados en Redes Neuronales

- *Self Organizing Maps* (SOM)

Métodos Aglomerativos

Algoritmo *Linkage*

La agrupación aglomerativa es un conjunto de algoritmos basados en la misma idea. La idea fundamental **es comenzar con cada punto de su propio clúster y**, para cada uno, usar un criterio para elegir otro clúster con el que fusionarse.

Linkage

La versión más básica es el algoritmo ***linkage* (enlace simple)**, que elige el clúster **más cercano** para **fusionar**, lo que permite clasificar el árbol por distancia, según el momento en que se fusionaron o dividieron los clústeres.

Métodos Aglomerativos

Algoritmo *Linkage*

Tenemos 5 puntos (*x, y, z*)

	X	Y	Z
ID_0	0.710129	0.291751	0.231301
ID_1	0.562128	0.733580	0.431405
ID_2	1.000000	0.698261	0.490364
ID_3	0.399808	0.349909	0.743349
ID_4	0.447174	0.060848	0.405851

Distancias

	ID_0	ID_1	ID_2	ID_3	ID_4
ID_0	0.000000	0.507108	0.562485	0.601560	0.391062
ID_1	0.507108	0.000000	0.443233	0.520442	0.682961
ID_2	0.562485	0.443233	0.000000	0.738634	0.847971
ID_3	0.601560	0.520442	0.738634	0.000000	0.446883
ID_4	0.391062	0.682961	0.847971	0.446883	0.000000

Métodos Aglomerativos

Algoritmo *Linkage*

Realizamos el enlace simple a partir de las métricas de distancias entre los puntos de los datos

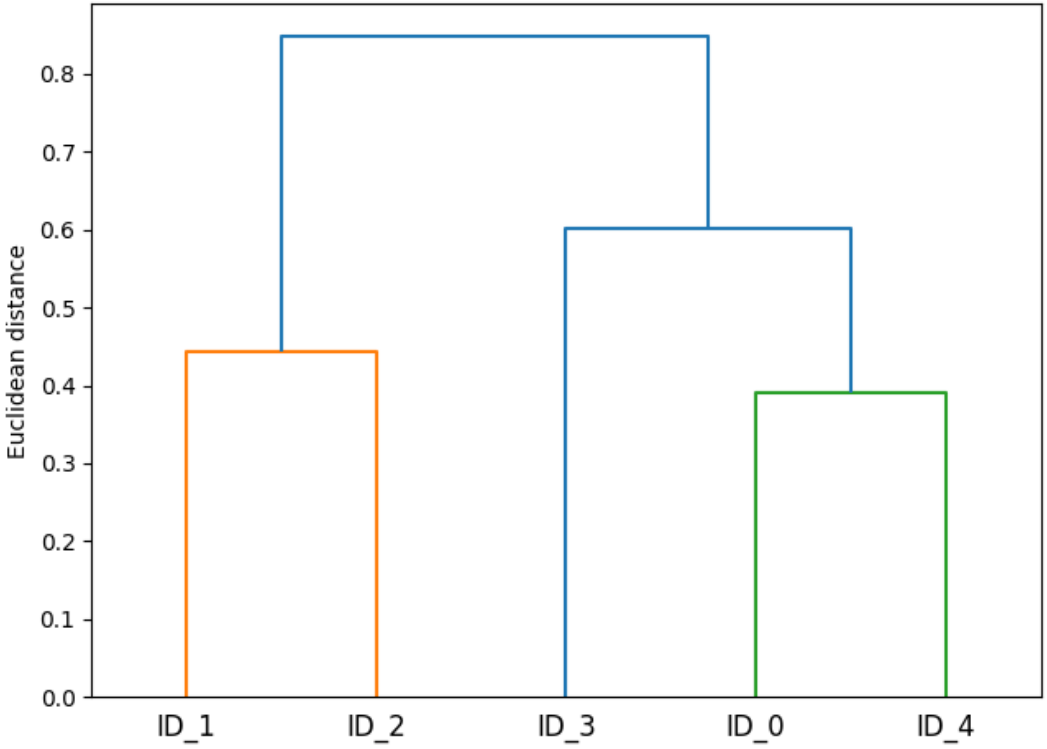

Métodos Basados en Partición

Algoritmo *KMeans*

La agrupación basada en partición divide los datos en grupos. La idea fundamental **es identificar el punto medio (*mean*) de cada clúster y**, para cada uno, determinar que datos están alrededor de esa media.

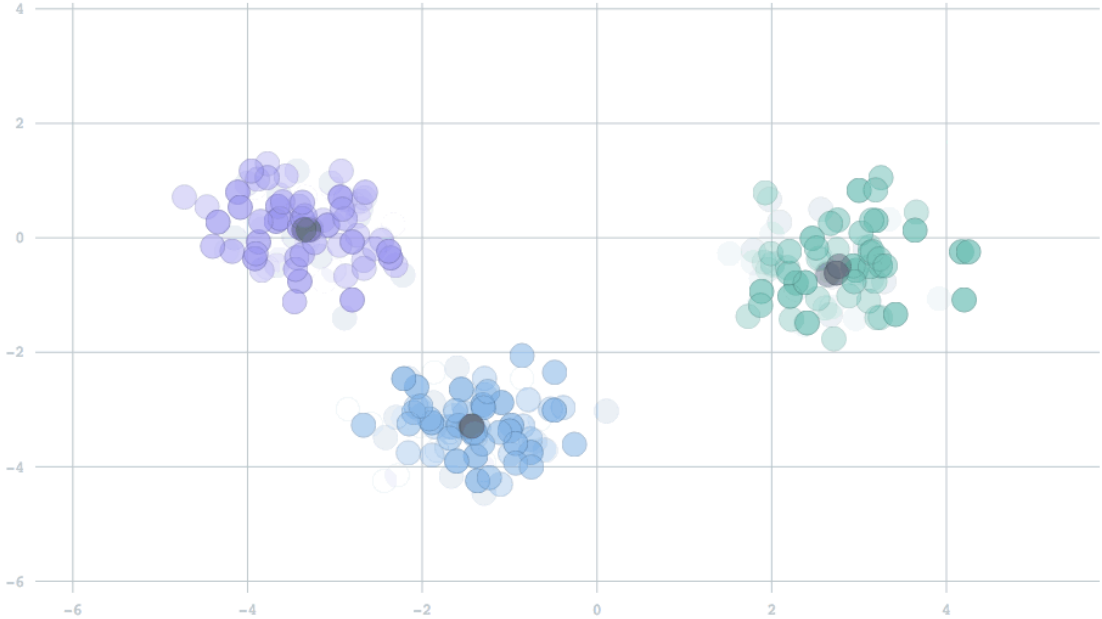

Algoritmo *Kmeans* (1/2)

(MacQueen, 1967)

Objetivo: minimizar la diferencia de los elementos dentro de cada clúster y maximizar la diferencia de los elementos en diferentes clústeres.

Entrada: Conjunto de datos ***X*** y ***k*** número de clústeres a formar;

Salida: **L** lista de clústeres en que caen las observaciones de ***X***.

Pasos:

1. Seleccionar los centroides iniciales de los K clústeres: $c_1, c_2, \ldots, c_K$.
2. Asignar cada observación $\boldsymbol{x}_i$ de ***X*** al clúster **C(i)** cuyo centroide **c(i)** está más cerca de $\mathbf{x}_i$.

$$C(i)=argmin_{1\leq k\leq K}||\boldsymbol{x}_i-\boldsymbol{c}_k||$$

3. Para cada uno de los clústeres se recalcula su centroide basado en los elementos que están contenidos en el clúster y minimizando la suma de cuadrados dentro del clúster:

$$WSS = \sum_{k=1}^{K} \sum_{C(i)=k} \| \mathbf{x}_i - \mathbf{c}_k \|^2$$

Ir al paso 2 hasta que se consiga convergencia

Métodos Basados en Partición

Algoritmo *Kmeans* (2/2)

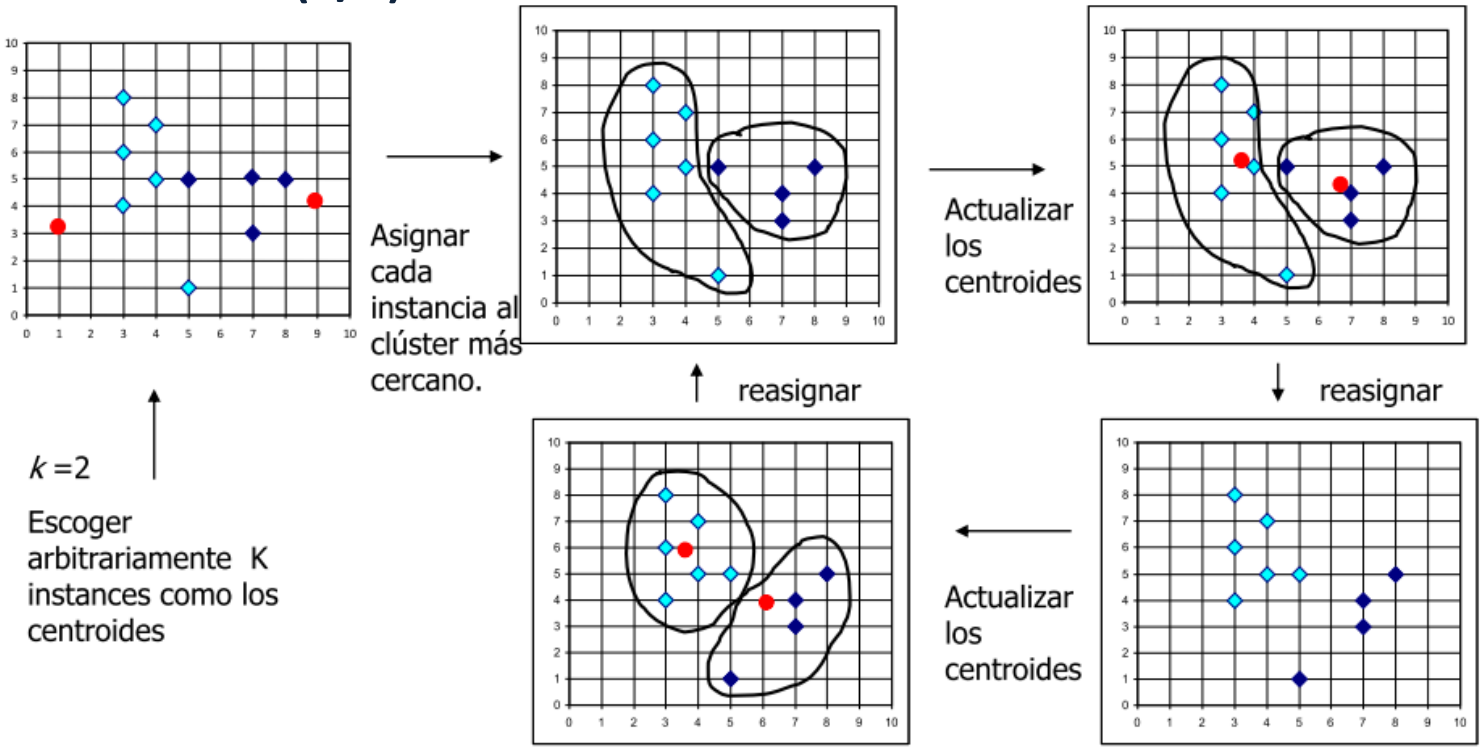

Métodos Basados en Densidad

Algoritmo DBSCAN

Density-Based Spatial Clustering of Applications with Noise

El DBSCAN es un algoritmo no supervisado muy conocido en materia de Clustering.
Fue presentado en 1996 por Martin Ester, Hans-Peter Kriegel, Jörg Sander y Xiawei Xu

Parámetros importantes:

- Número de puntos (MinPts)
- Radio de distancia

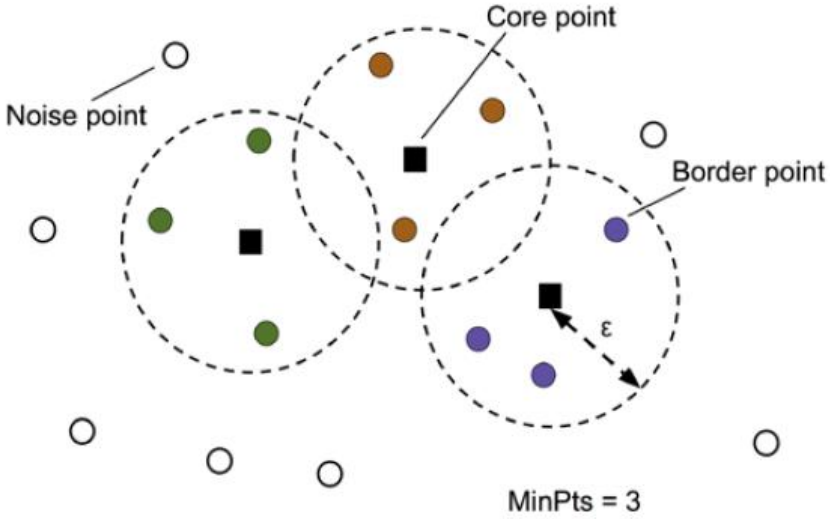

Métodos Basados en Densidad

Algoritmo DBSCAN

El **DBSCAN** es un algoritmo sencillo que define los clústeres mediante la estimación de la densidad local. Se puede dividir en 4 etapas:

1. Para cada observación miramos el número de puntos a una distancia máxima ε de ella. Esta zona se denomina **ε-vecindad** de la observación.
2. Si una observación tiene al menos un cierto número de vecinos, incluida ella misma, se considera una observación central. En este caso, se ha detectado una observación de alta densidad.
3. Todas las **observaciones** en la vecindad de una **observación central** pertenecen al mismo clúster. Puede haber observaciones centrales cercanas entre sí. Por lo tanto, de un paso a otro, se obtiene una larga secuencia de observaciones centrales que constituyen un único clúster.
4. Cualquier observación que no sea una observación central y que no tenga ninguna observación central en su vecindad se considera una **anomalía**.

Hiperparámetros:

- **ε-vecindad:** eps
- **Número mínimo de vecinos:** min_samples

Métodos Basados en Redes Neuronales

Modelo ART

Adaptive Resonance Theory (Redes **ART**), genera una neurona por cada patrón que encuentra en los dos datos con dos capas.

Es un modelo de redes neuronales y una teoría cognitiva desarrollada por Stephen Grossberg y Gail Carpenter en 1987.

Su objetivo es resolver el dilema de estabilidad-plasticidad: cómo un sistema puede aprender nueva información (plasticidad) sin olvidar o corromper lo que ya sabe (estabilidad)

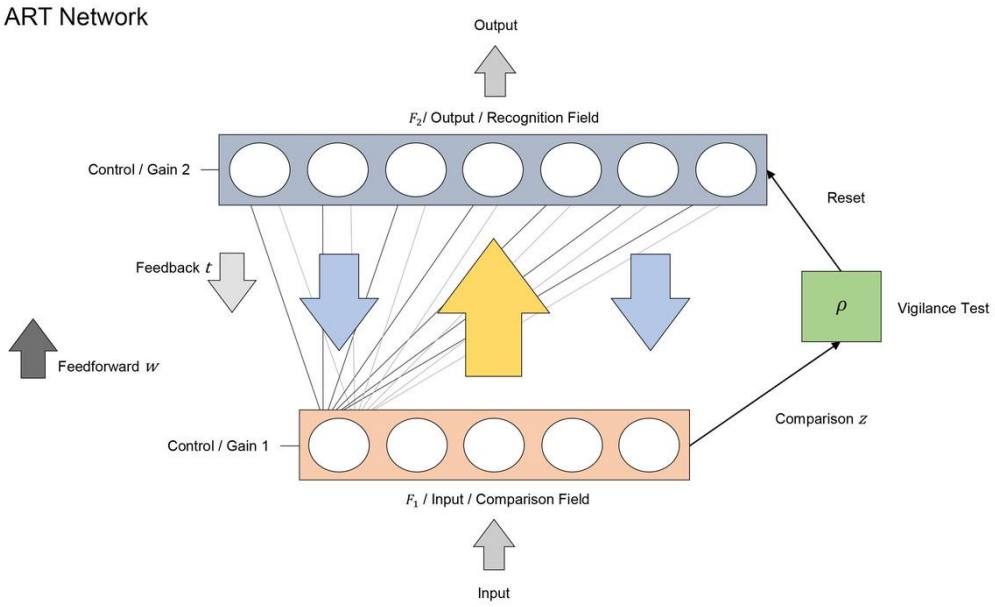

Métodos Basados en Redes Neuronales

Self Organizing Maps - SOM (1/3)

Mapeamiento de datos en 2 dimensiones

Preproceso antes de agrupamiento de datos

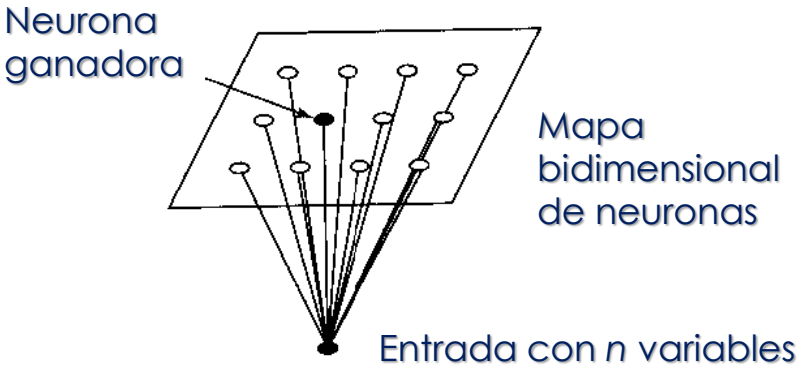

Métodos Basados en Redes Neuronales

Self Organizing Maps - SOM (2/3)

Transforma patrones entrada de dimensión arbitraria en un mapa discreto de una o dos dimensiones

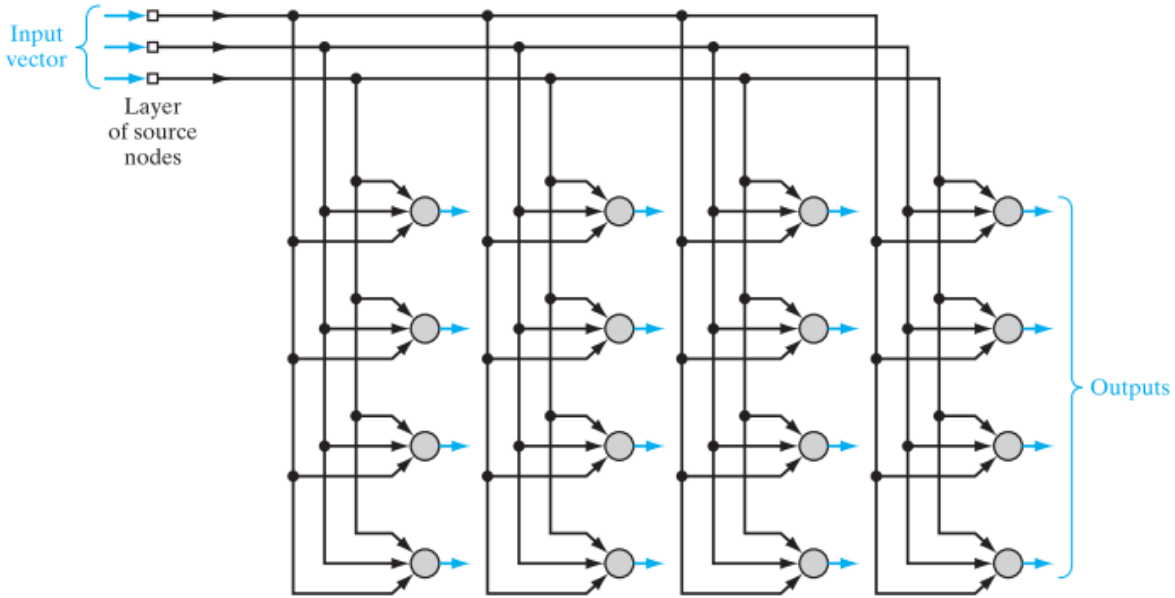

Métodos Basados en Redes Neuronales

Self Organizing Maps - SOM (3/3)

Entrenamiento: Proceso Competitivo

Tenemos: **Datos de entrada** $\mathbf{x} = [x_1, x_2, \ldots, x_m]^T$ y **pesos** $\mathbf{w}_j = [w_{j1}, w_{j2}, \ldots, w_{jm}]^T, \quad j = 1, 2, \ldots, l$

Comparamos el vector de entrada **x** con los pesos **w** a través de un producto punto $\mathbf{w}_j^T\mathbf{x}$ esto nos genera una medida de **distancia**.

Escogemos la neurona que más se acerque al vector de entrada de la forma:

$$i(\mathbf{x}) = \arg\min_j \|\mathbf{x} - \mathbf{w}_j\|, \quad j = 1, 2, \ldots, l$$

Cuando la neurona satisface dicha condición, decimos que es la **neurona ganadora**

Métodos Basados en Redes Neuronales

Self Organizing Maps - SOM (1/3)

Entrenamiento: Proceso Cooperativo

La neurona ganadora se vuelve el centro topológico de neuronas cooperativas (evidencia neurobiológica)

Definimos una función $h_{j,i}$ de vecindad **unimodal** y con distancia lateral entre neuronas, que satisface:

- Es simétrica alrededor del punto máximo definido como $d_{i,j} = 0$
- La amplitud de $h_{j,i}$ decrece monotónicamente a medida que la distancia lateral aumenta

$$h_{j,i(\mathbf{x})} = \exp\left(-\frac{d_{j,i}^2}{2\sigma^2}\right)$$

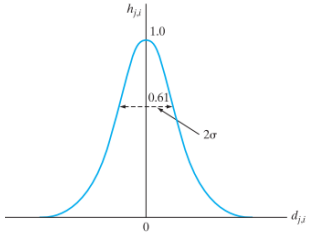

$$\sigma(n) = \sigma_0 \exp\left(-\frac{n}{\tau_1}\right)$$

Métodos Basados en Redes Neuronales

Self Organizing Maps - SOM (1/3)

Entrenamiento: Proceso Adaptativo (autoorganización y convergencia)

Basado en el postulado de Hebb

La actualización de cada peso sináptico queda de la forma:

$$\Delta \mathbf{w}_j = \eta y_j \mathbf{x} - g(y_j)\mathbf{w}_j$$

Obtenemos para al actualización:

$$\Delta \mathbf{w}_j = \eta h_{j,i(\mathbf{x})}(\mathbf{x} - \mathbf{w}_j)$$

Finalmente para la actualización de los pesos sinápticos

$$\mathbf{w}_j(n+1) = \mathbf{w}_j(n) + \eta(n) h_{j,i(\mathbf{x})}(n)(\mathbf{x} - \mathbf{w}_j(n))$$

Y para η

$$\eta(n) = \eta_0 \exp\left(-\frac{n}{\tau_2}\right), \qquad n = 0, 1, 2, \ldots,$$

Métodos Basados en Redes Neuronales

Self Organizing Maps - SOM (1/3)

Evaluación del mapa entrenado:

Inspección visual cualitativa basada en la U-matriz

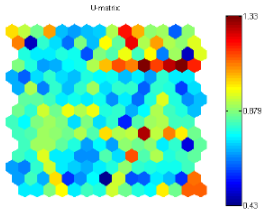

Evaluación cuantitativa basada en:

Error de cuantización: Corresponde a la media del error de los N patrones usados en el entrenamiento

$$Q_e = \frac{1}{N}\sum_{k=1}^{N} \|\mathbf{x_k} - \mathbf{w_{BMU}}\|$$

Error topográfico: que evalúa cuánto las neuronas del mapa se aproximan a los patrones existentes en el espacio de entrada.

$$T_e = \frac{1}{N}\sum_{k=1}^{N} u(x_k)$$

Métodos Basados en Redes Neuronales

Ejemplo (pesos) – Agrupamiento de Colores

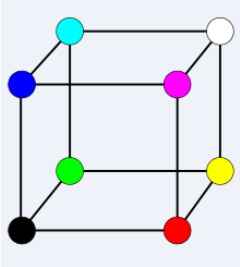

Queremos agrupar una matriz de valores al azar.

- La matriz es compuesta de tres matrices, cada una a una representación de codificación de color R,G,B
- Usamos un mapa auto-organizado

SOM

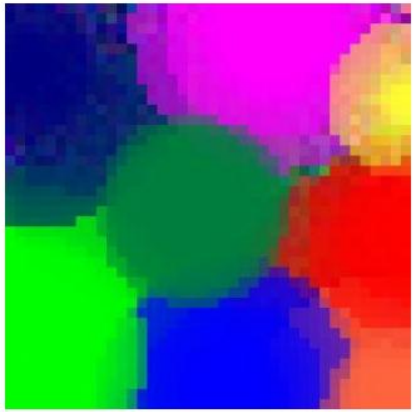

Métodos Basados en Redes Neuronales

Ejemplo (pesos) – Agrupamiento de Información de Bioseñales

Permite determinar patrones importantes en los datos (muestras) usados

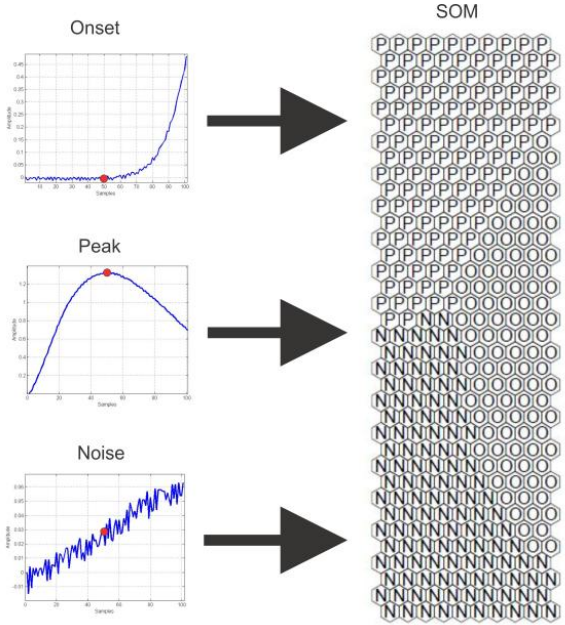

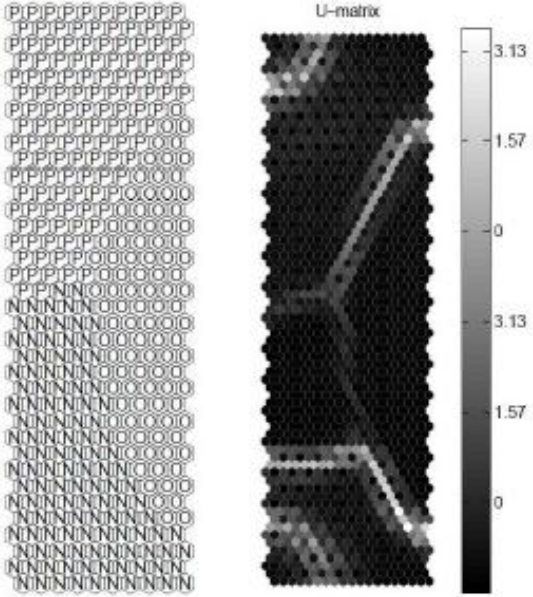

Métodos Basados en Redes Neuronales

Ejemplo: Apoyo Diagnóstico de TB con SOM+*KMeans*

Usamos un mapa para agrupar datos de pacientes con sospecha de TB pulmonar

Variables Usadas

- Edad
- Sexo
- HIV Status
- Tabaquismo
- ADA
- BAAR
- Cultivo líquido pleural
- ELISA
- PCR

Fonte: www.oktono.com

Tipo de Pacientes	Número de pacientes
TB positivo	74
TB negativo	39

Métodos Basados en Redes Neuronales

Ejemplo: Apoyo Diagnóstico de TB con SOM+*KMeans*

Arquitectura construída a partir de análisis MCA

Agrupamento usando o algoritmo *k-means*

- Tres *Clusters*

  Determinados por la incidencia de la enfermedad

  - Alto
  - Medio
  - Bajo

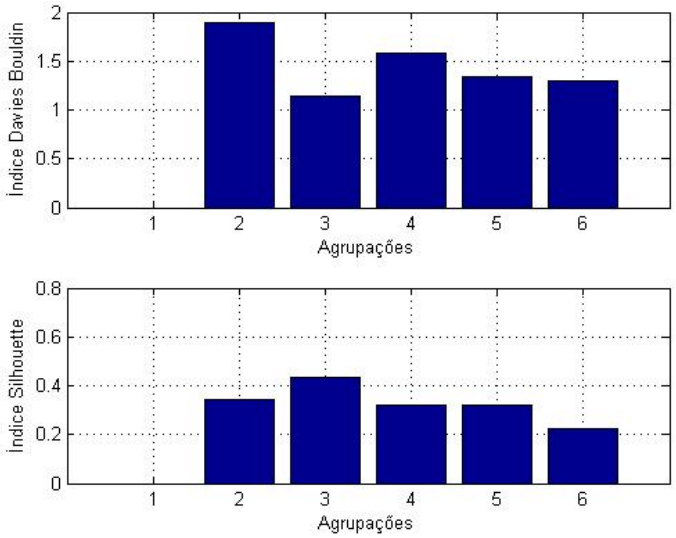

Métodos Basados en Redes Neuronales

Ejemplo: Apoyo Diagnóstico de TB con SOM+*KMeans*

Permiten el análisis de los pacientes que van llegando después de obtenido el mapa

Datos de Pacientes con la enfermedad

Datos de Pacientes sin la enfermedad

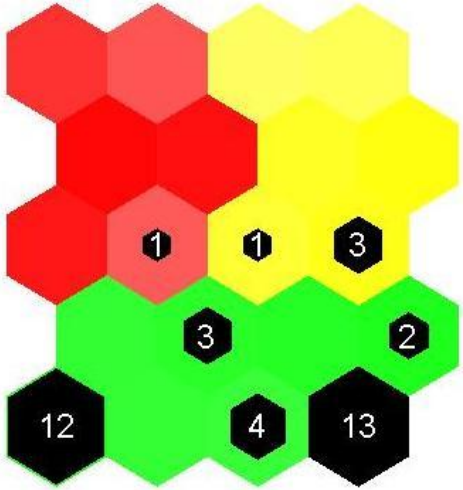

Pacientes sin la enfermedad

Ejemplo: Apoyo Diagnóstico de TB con SOM+*KMeans*

Podemos calcular resultados de agrupamiento en términos de detección de la enfermedad

RIESGO	Con TB	Sin TB	Total
Alto (Rojo)	**31 (97%)**	1 (3%)	32
Medio (Amarillo)	36 (90%)	4 (10%)	40
Bajo (Verde)	7 (17%)	**34 (83%)**	41

- Sensibilidad = 90%
- Especificidad = 87%

Métodos Basados en Redes Neuronales

Ejemplo: Apoyo Diagnóstico de TB con SOM+*KMeans*

Permiten analizar las variables involucradas

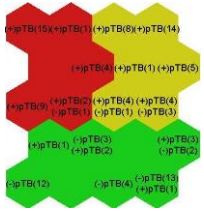

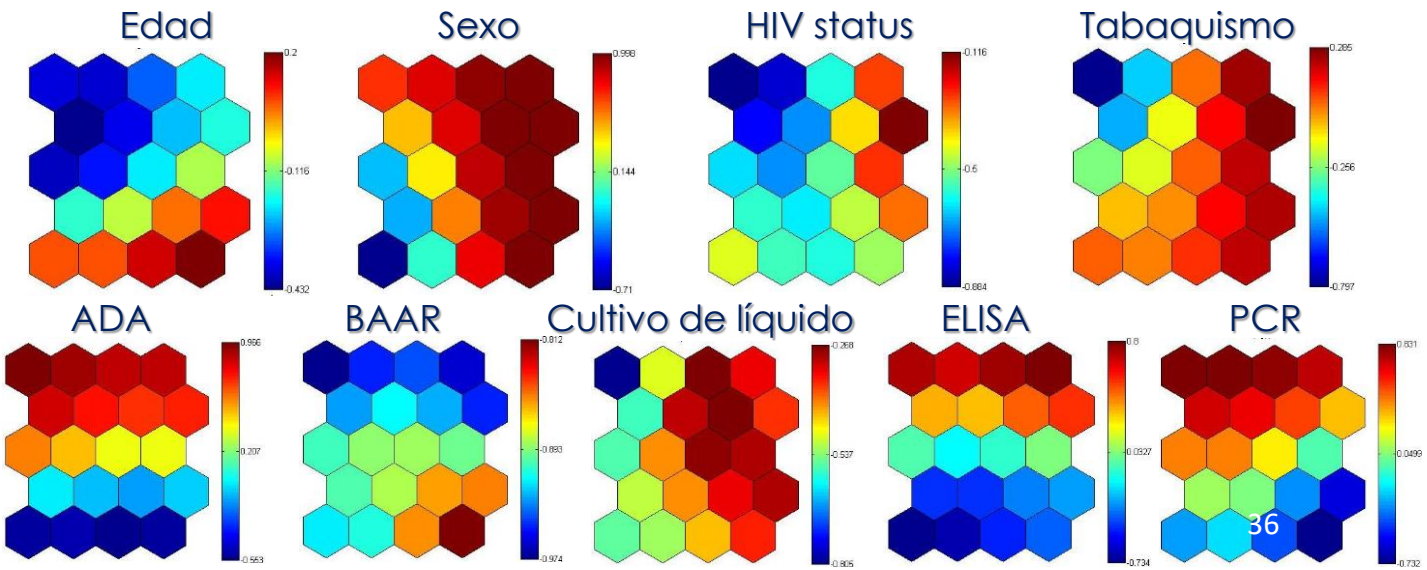

Comentarios Finales

- Los SOM son basante útiles en procesos previos al agrupamiento debido a su representación principalmente en 2D
- Pueden combinarse diferentes tipos de entradas (binarias, reales, continuas)
- Presentan información valiosa acerca de las variables del problema
- Es necesario realizar un buen proceso de evaluación del agrupamiento

Referencias

LIBROS

- Haykin, Simon S., et al. Neural networks and learning machines. Vol. 3. Upper Saddle River, NJ, USA:: Pearson, 2009.
- Kohonen, Teuvo, Self Organizing Maps, Springer, 2000
- Duda, Richard O., Peter E. Hart, and David G. Stork. Pattern classification. John Wiley & Sons, 2012.
- Agresti, Alan. Categorical data analysis. Vol. 482. John Wiley & Sons, 2003.

ARTÍCULOS:

- J. Vesanto and E. Alhoniemi, “Clustering of the Self-Organizing Map”, IEEE Transactions on Neural Networks, Vol. 11, No. 3, pp. 586-600, 2000
- Kohonen, Teuvo, et al. "Engineering applications of the self-organizing map." Proceedings of the IEEE 84.10 (1996): 1358-1384.

¿DUDAS?

GRACIAS